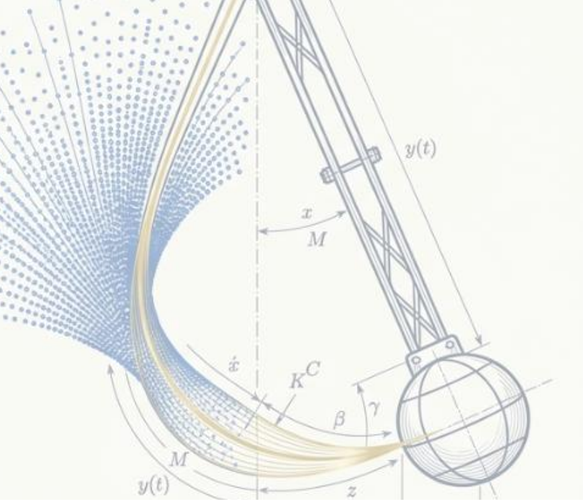

Nhập Môn Học Máy

GVHD: PGS.TS. Lê Hoàng Thái, ThS. Huỳnh Lâm Hải Đăng

HỌC ĐA TẠP
CHO NHẬN DẠNG HỆ THỐNG VẬT LÝ

Ninepls

Thành viên

Lại Nguyễn Hồng Thanh_23122018
Phan Huỳnh Châu Thịnh_23122019
Nguyễn Gia Bảo_23122015

TỔNG QUAN

01 Giới thiệu

02 Phương pháp

03 Bài toán

04 Thực nghiệm

05 Thảo luận

01

DL & OVERFITTING

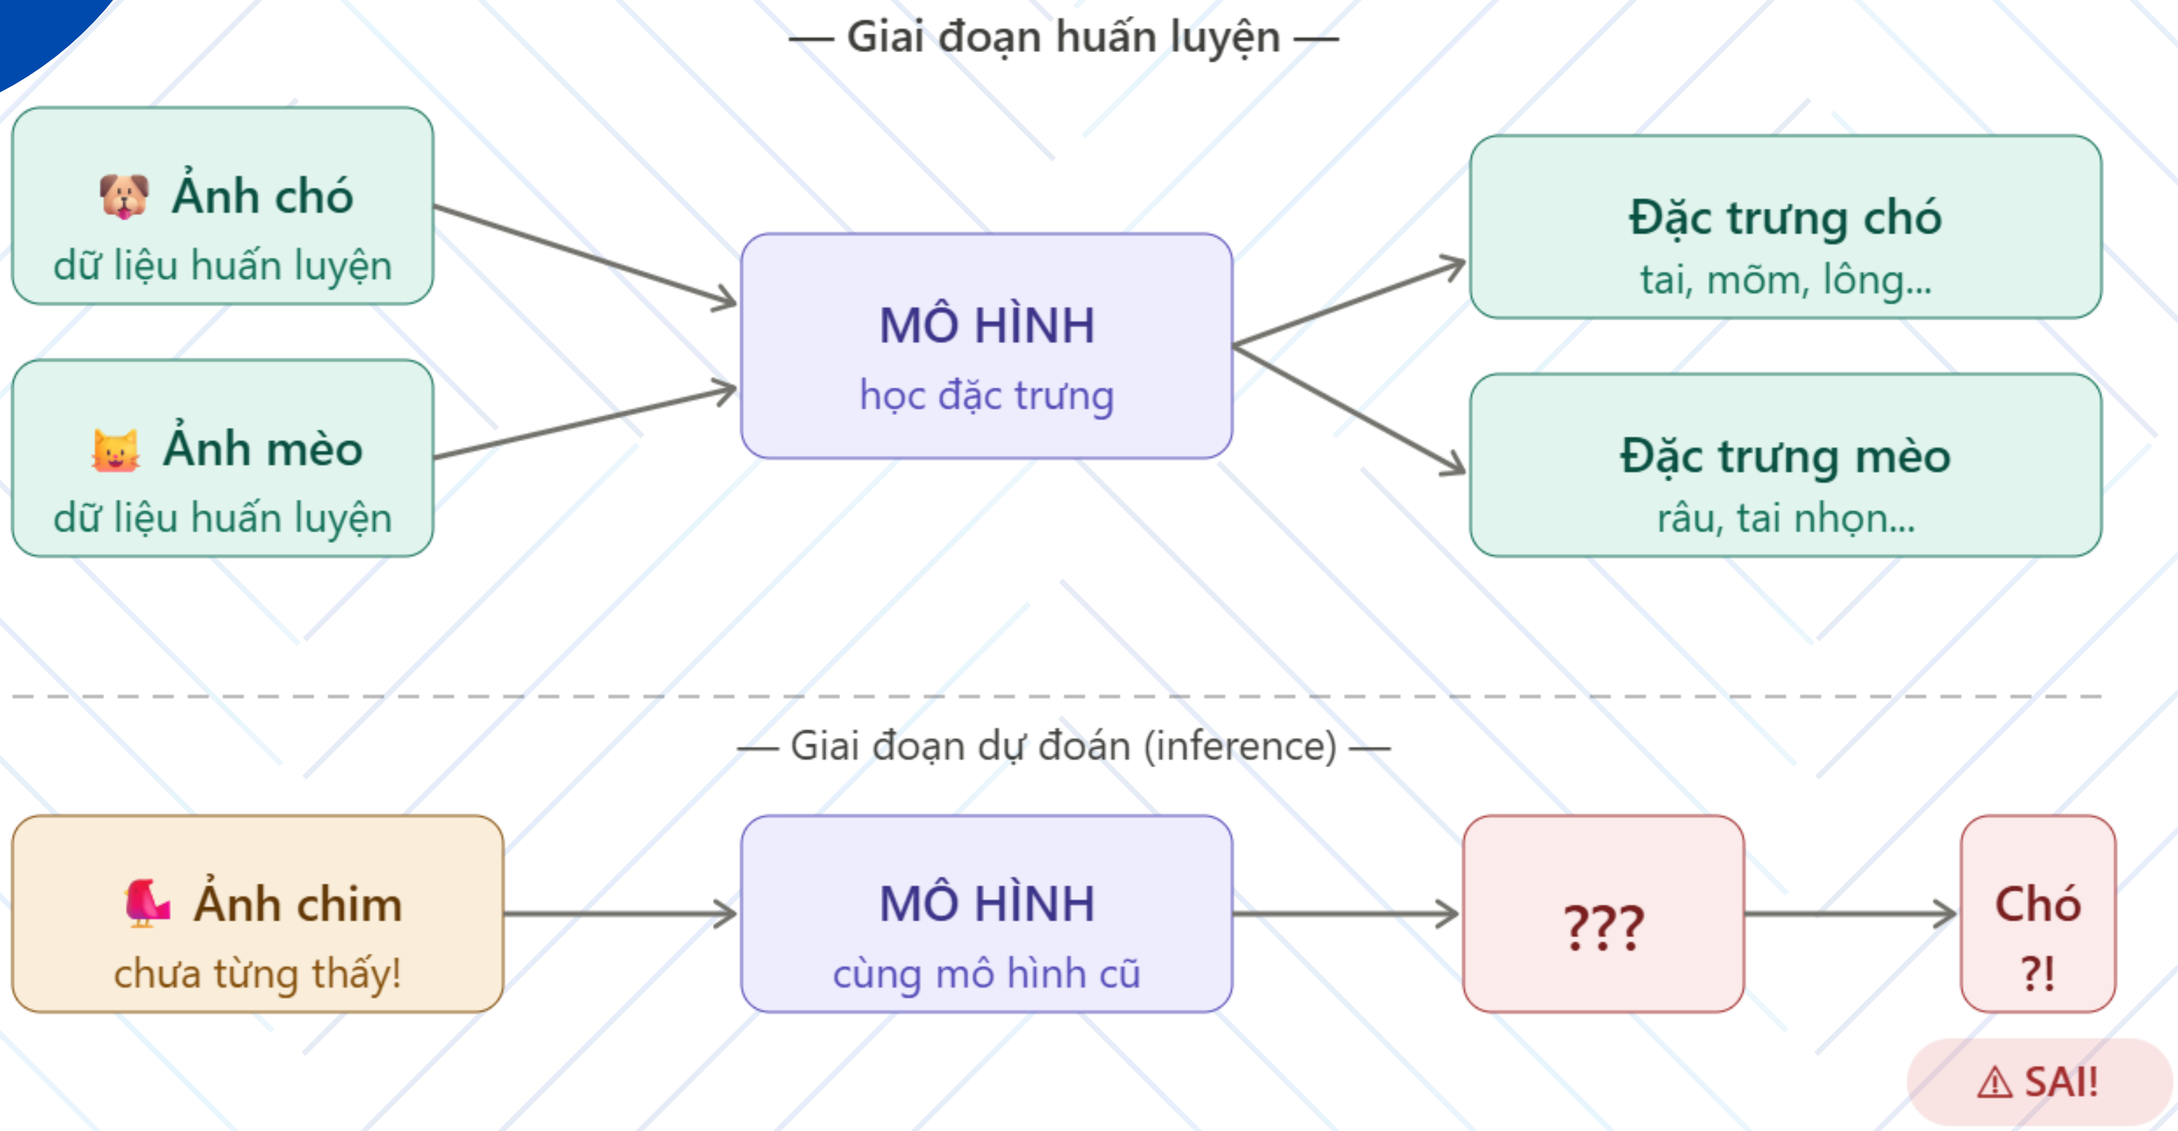

01

META-LEARNING

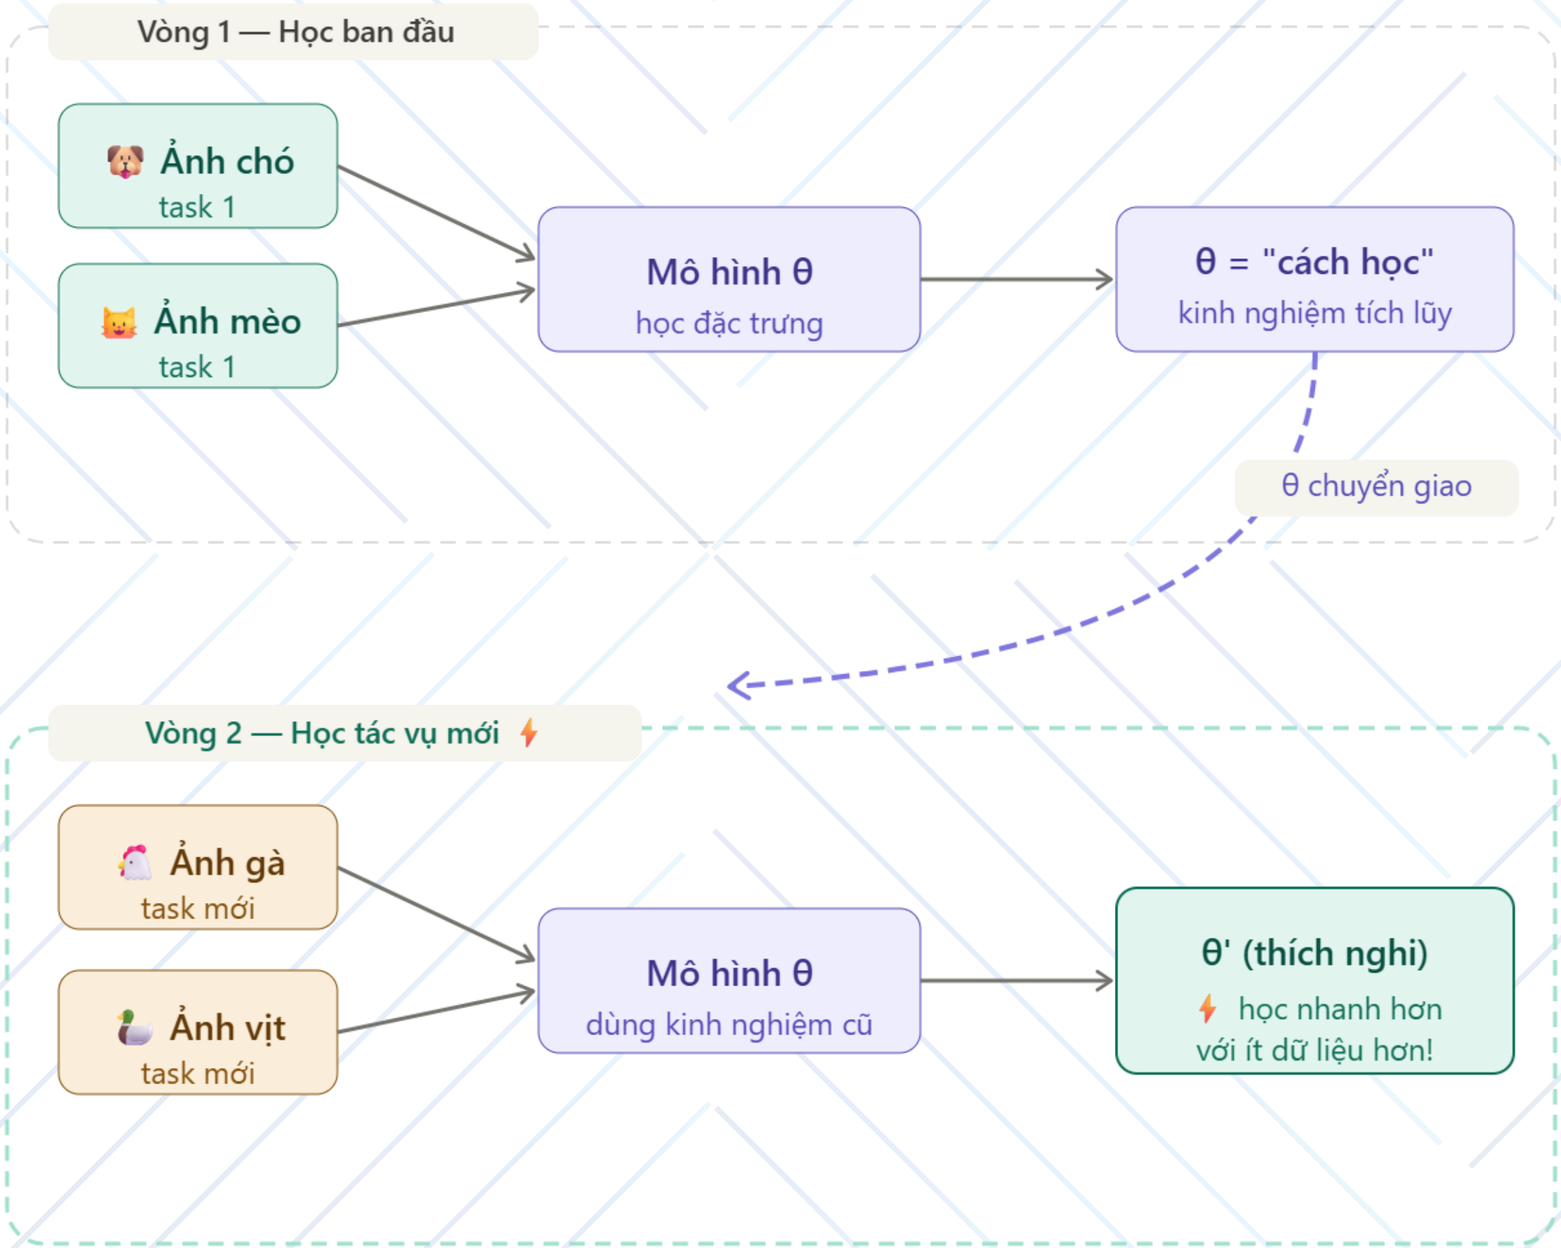

01

MAML

So sánh hai chiến lược tối ưu trọng số

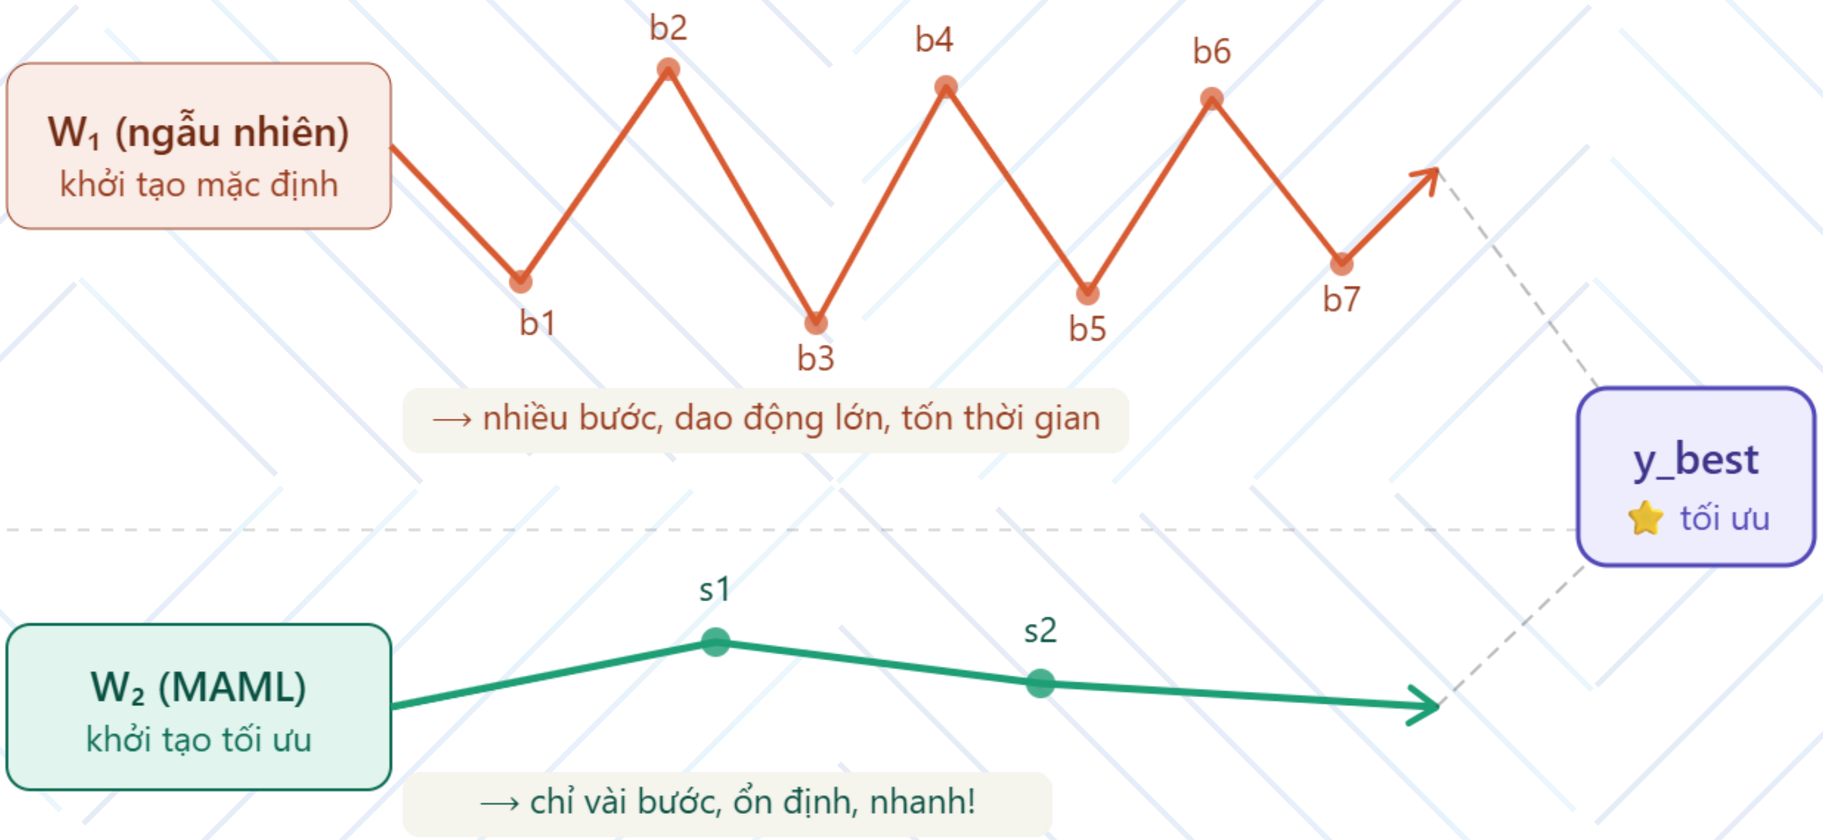

Phương pháp	Số bước	Hiệu quả
W_1 ngẫu nhiên	~7+ bước, zigzag	chậm ✗
W_2 MAML	~2–3 bước, ổn định	nhanh ✓

01

BLACK-BOX

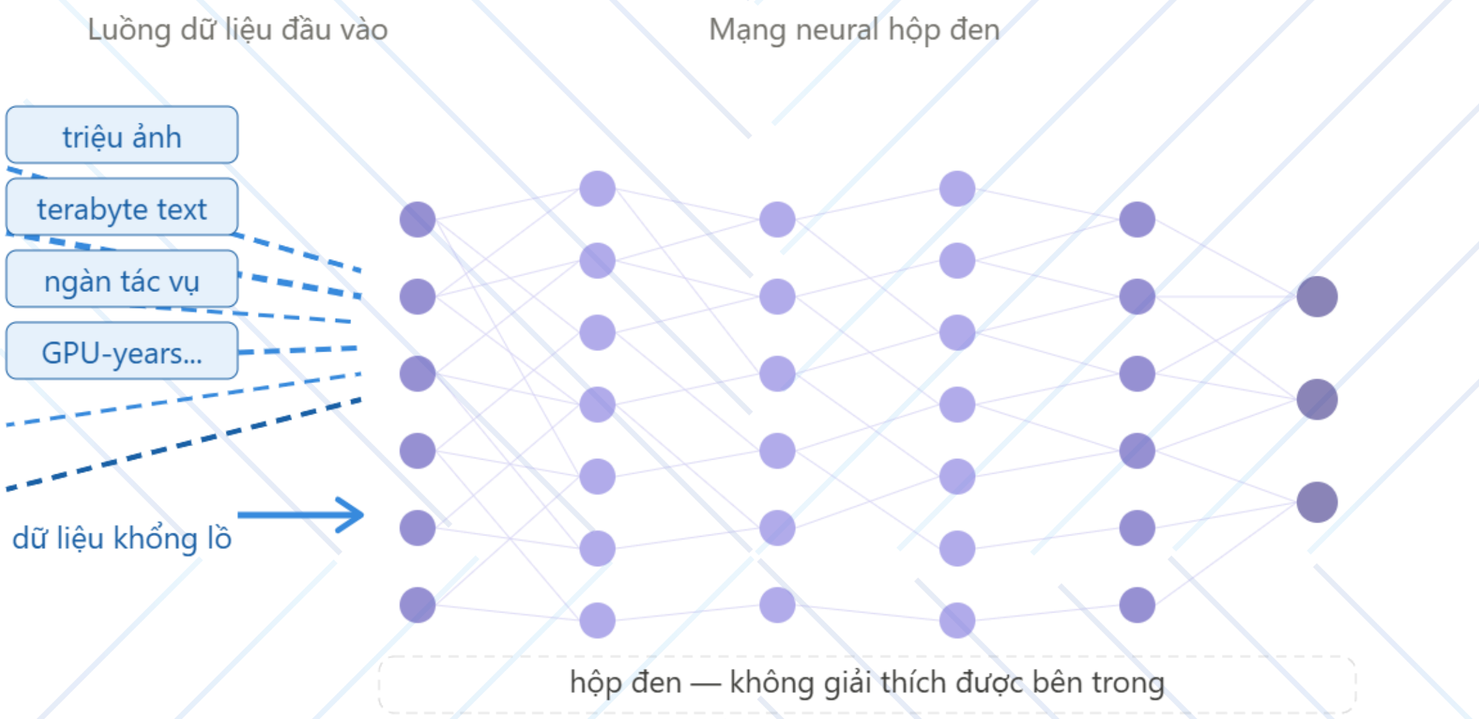

Chi phí tính toán

∞ FLOP

thấp | cao | vô hạn

GPU tháng
hàng nghìn giờ

Chi phí $$$
hàng triệu USD

Dữ liệu
cần cực kỳ nhiều

Black-box: hiệu quả nhưng không bền vững với mọi tổ chức

01

BASE & VẬT LÝ

$$\hat{y} = F(u; \theta)$$

F: Kiến trúc cơ sở (Neural State-Space Model).

θ: Tham số của mạng nơ-ron ($\theta \in \mathbb{R}^{n_\theta}$).

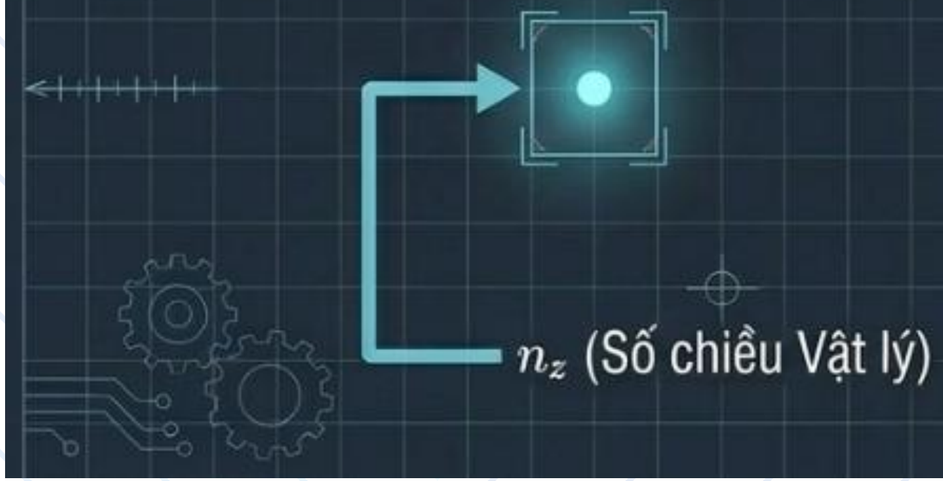

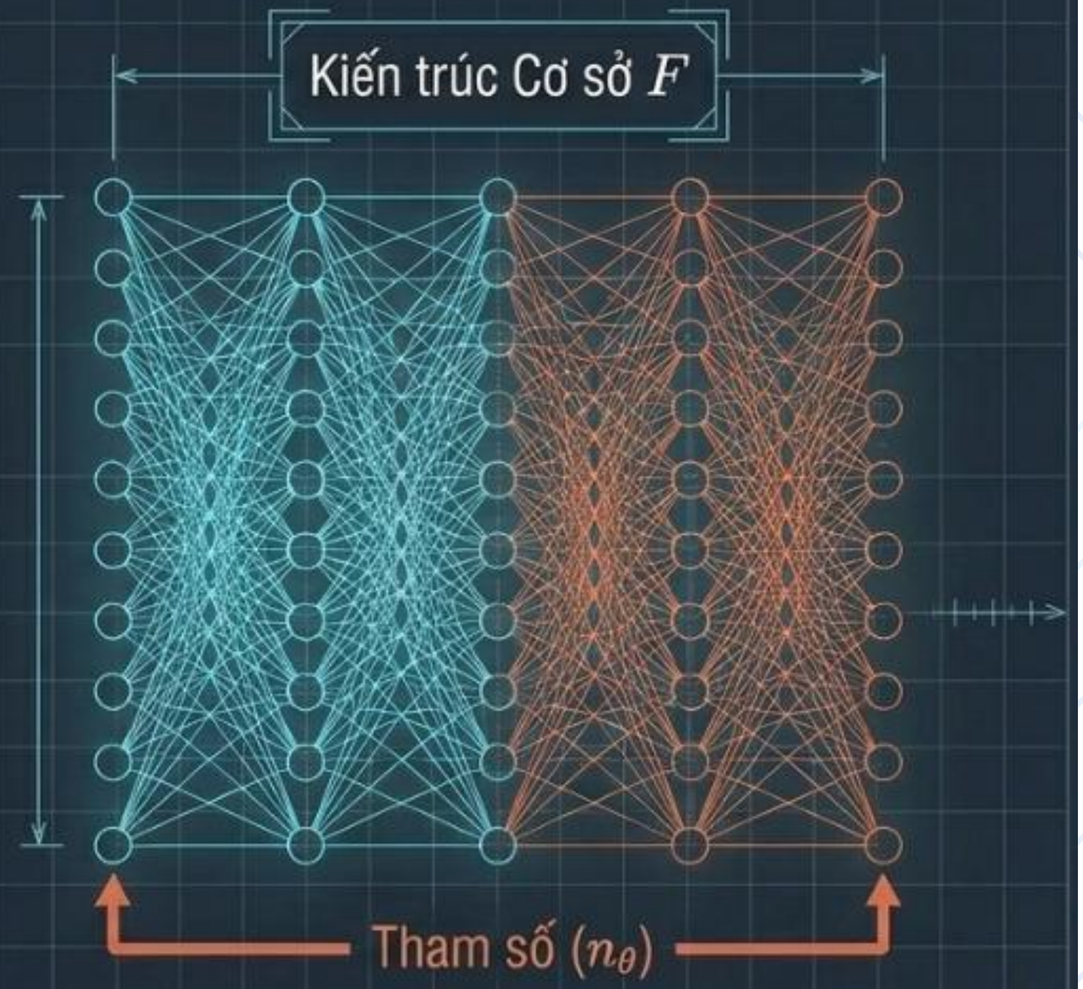

01

ĐỘNG LỰC VẬT LÝ

$$x(t) = A\cos(\omega t + \varphi)$$

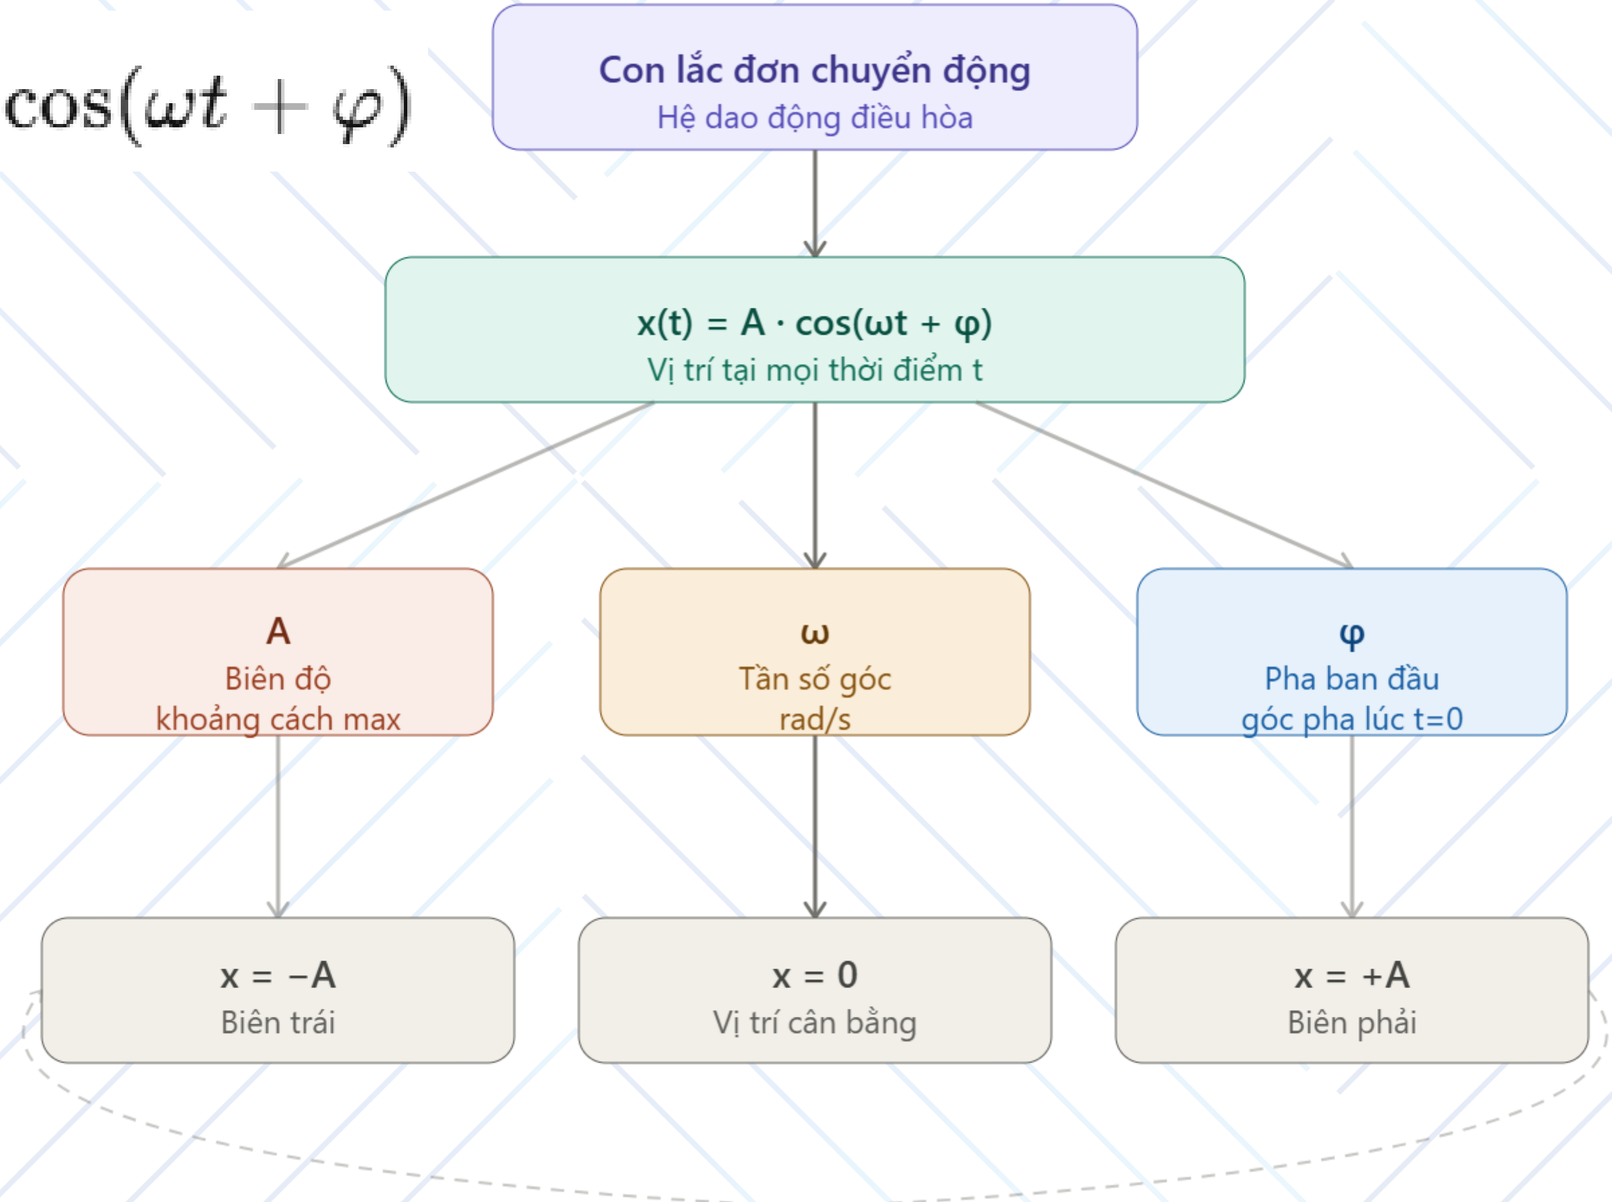

01 LEO & KHÔNG GIAN ẨN

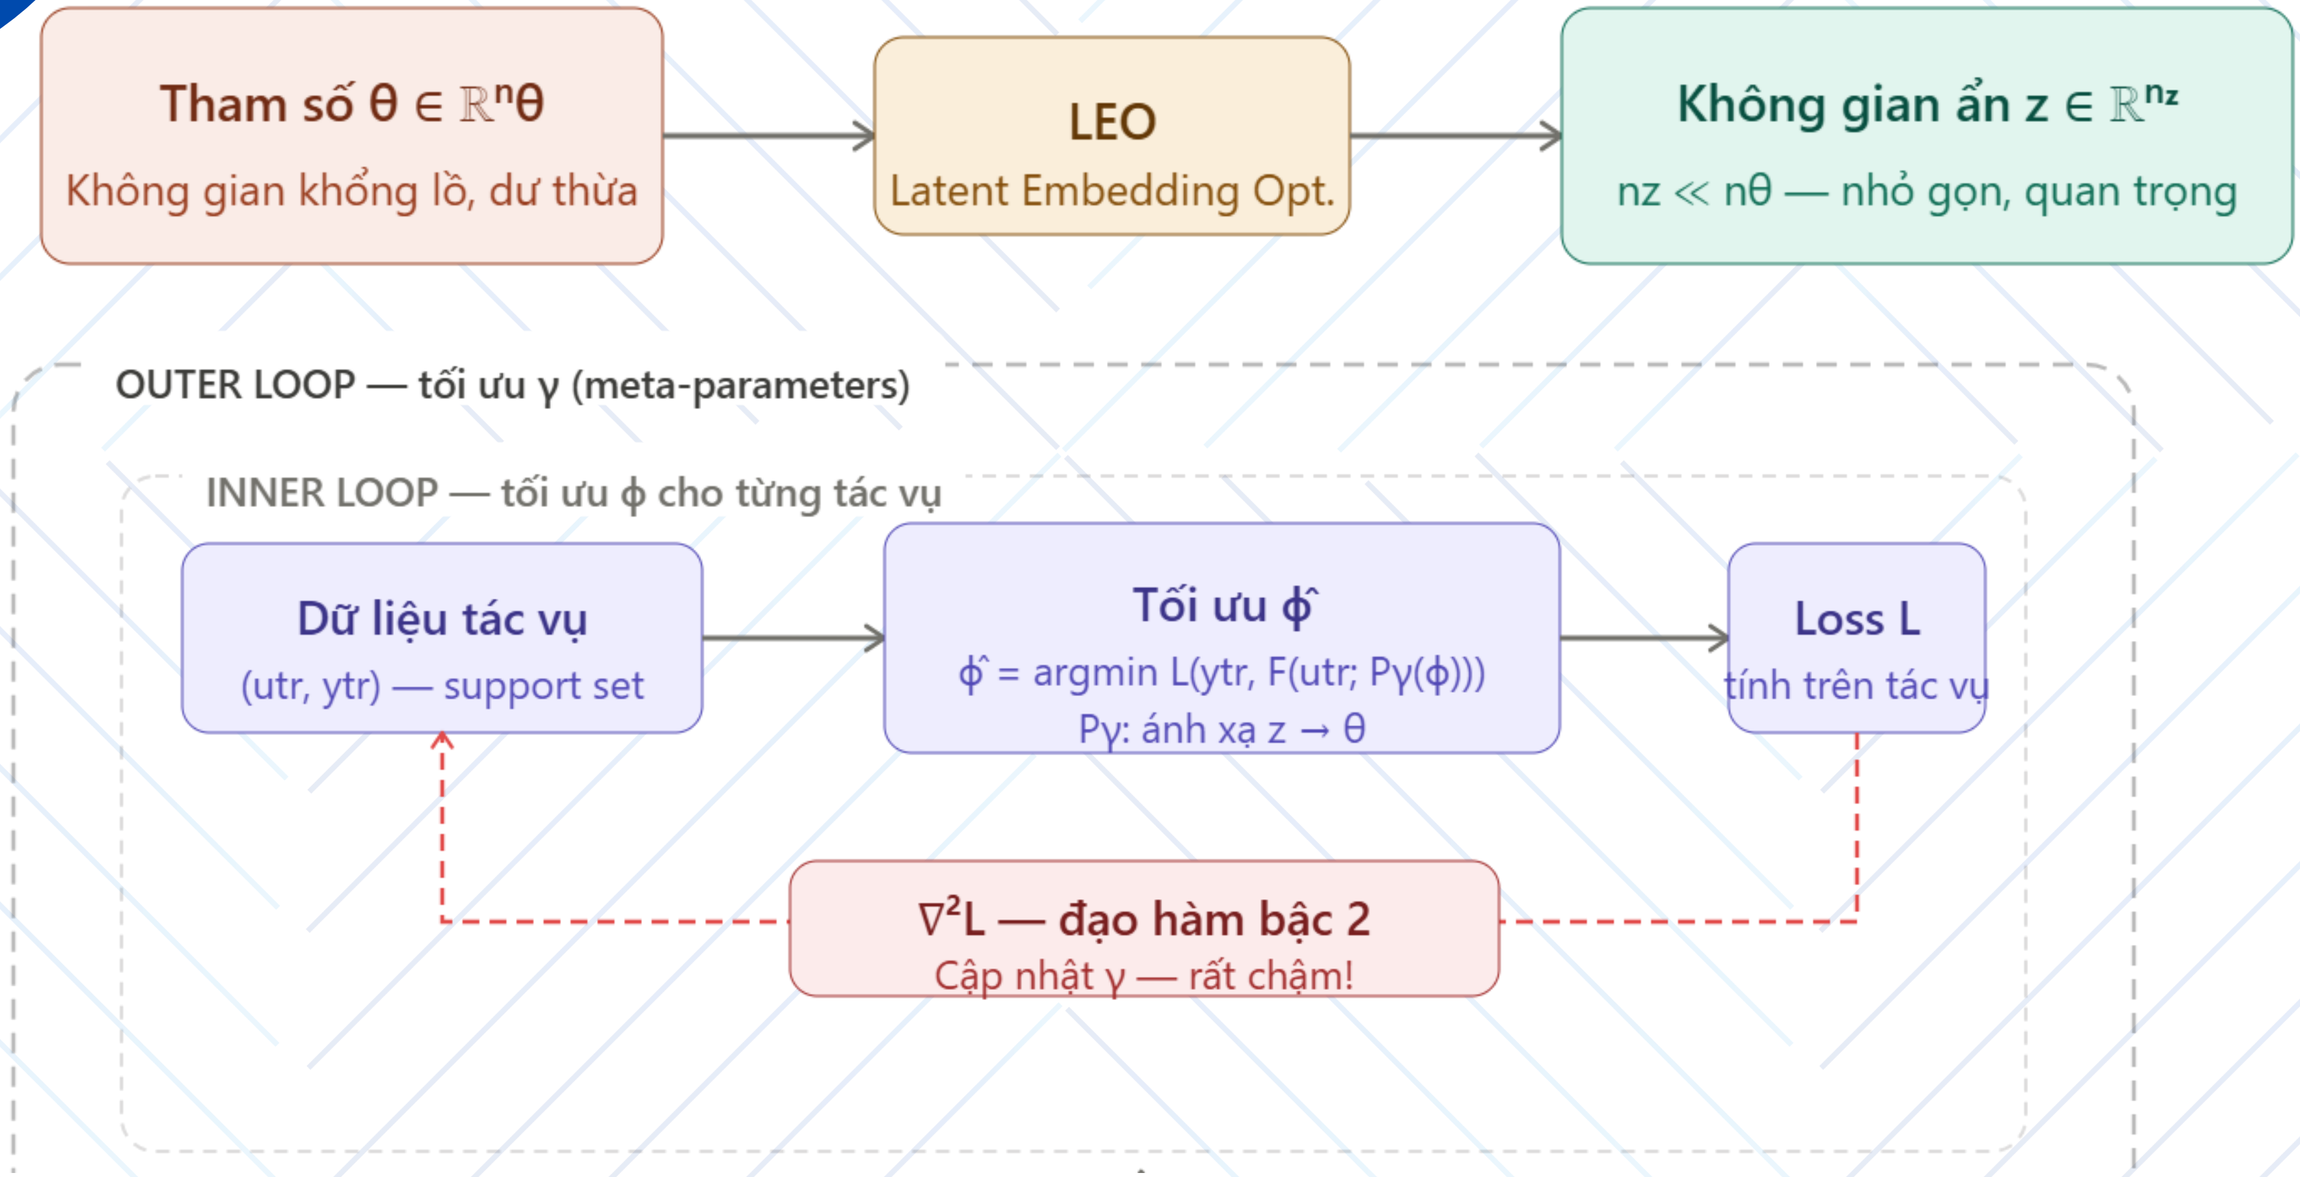

02 MANIFOLD META-LEARNING

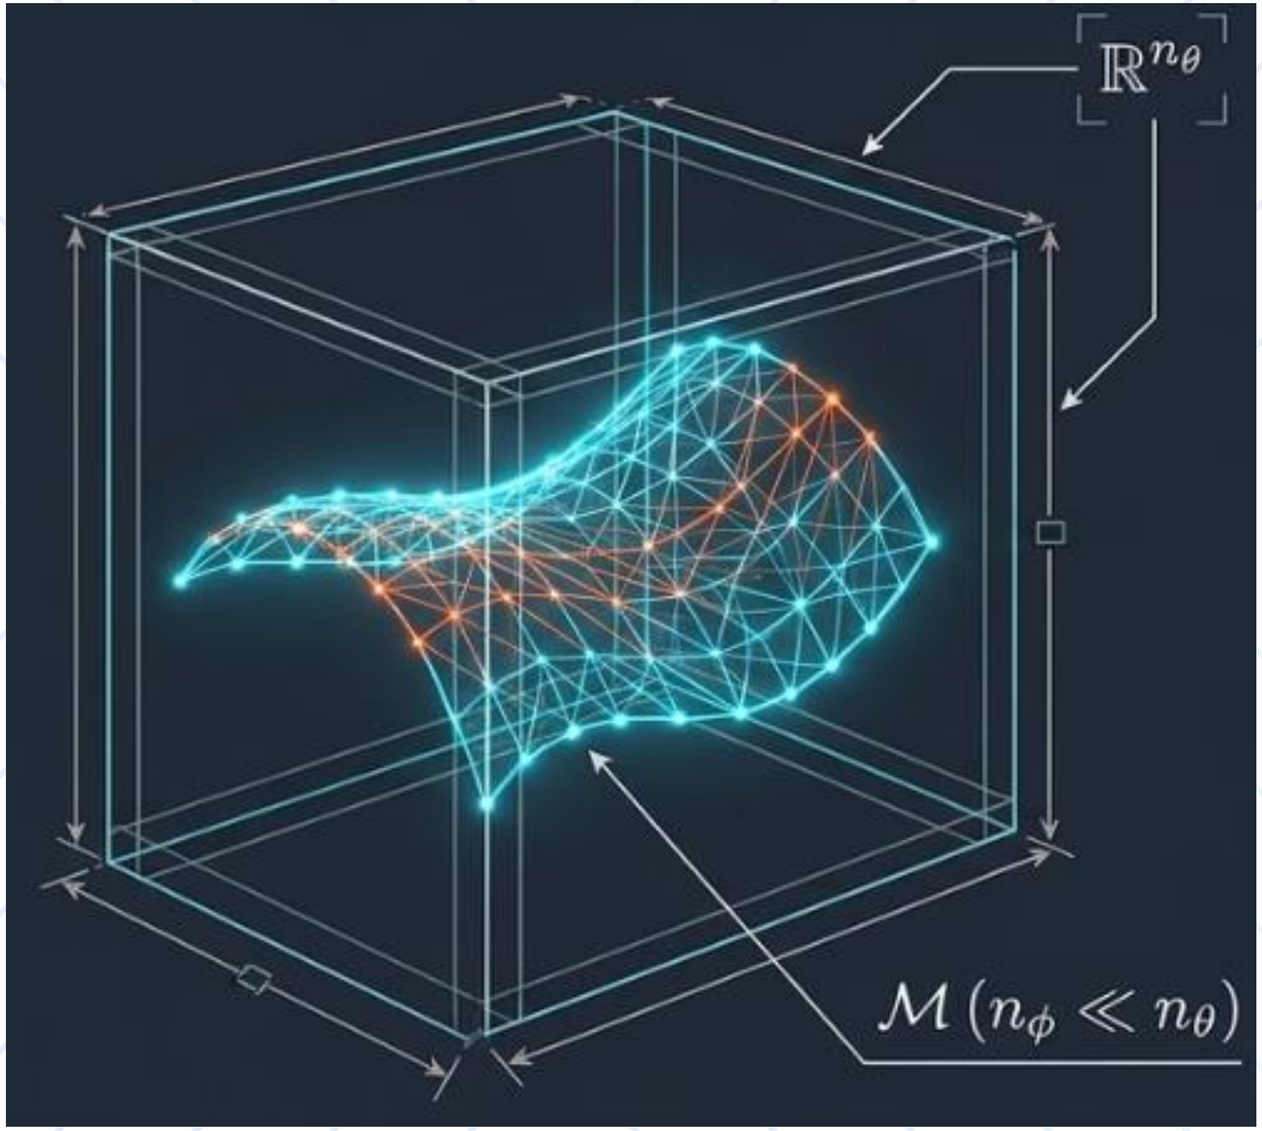

02

MANIFOLD ENCODER

Dữ liệu tác vụ

(u_tr, y_tr) — input & output pairs

Encoder E_ψ

Bi-directional GRU
đọc chuỗi đầu vào

Feed-forward NN
ánh xạ sang không gian φ

Đọc toàn bộ D_tr chỉ một lần — không có vòng lặp trong

φ̂ = E_ψ(u_tr, y_tr)

φ̂ ∈ ℝⁿφ

n_φ = 20 — không gian con rất nhỏ!

Tham số hóa đa tạp con

Thay vòng lặp trong bằng một lần forward pass

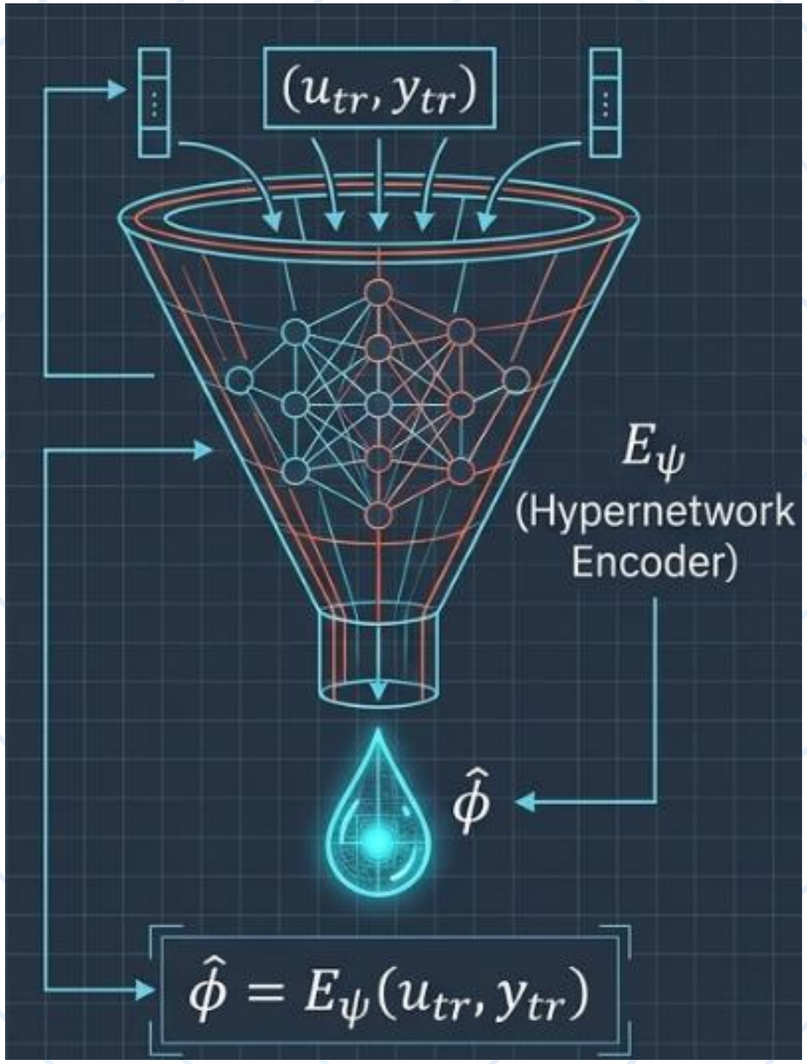

02 LIFTING& KIẾN TRÚC

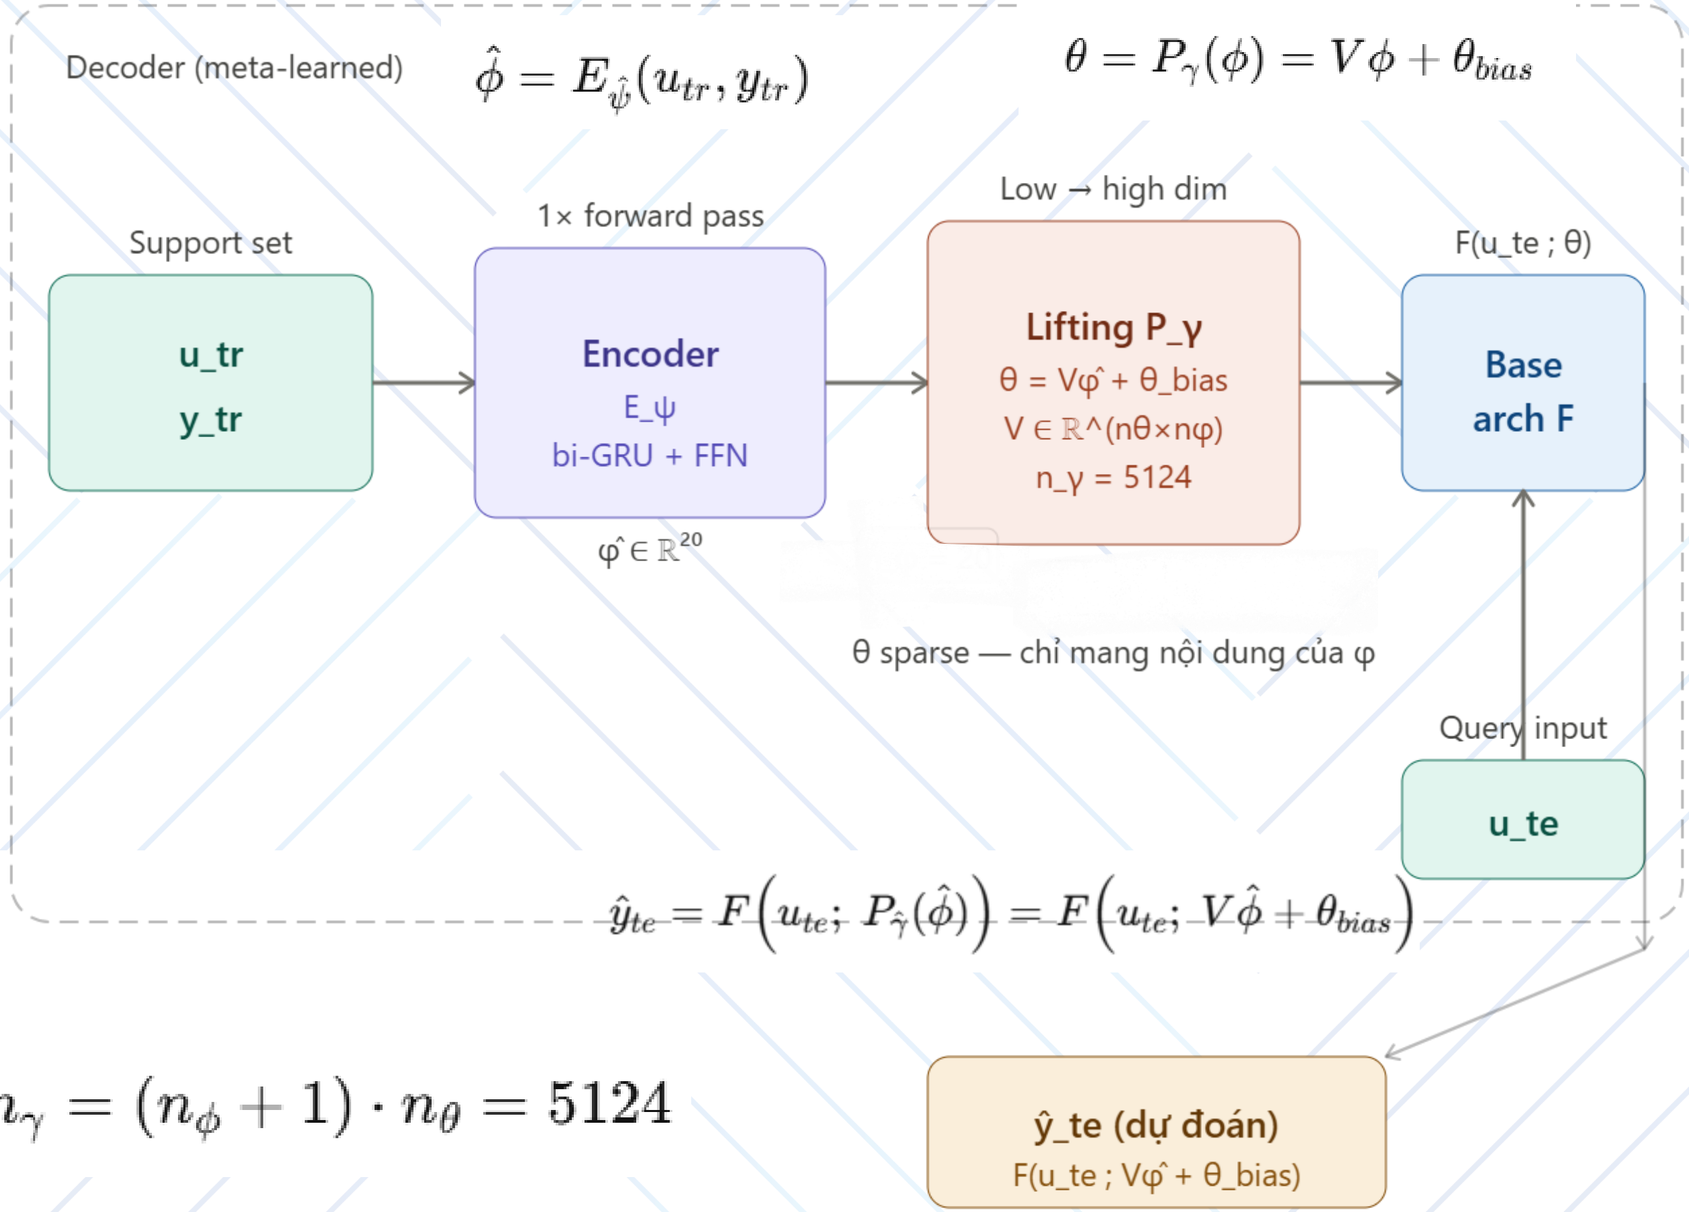

$V \in \mathbb{R}^{n_\theta \times n_\phi}$ — ma trận ánh xạ

$\theta_{bias} \in \mathbb{R}^{n_\theta}$ — vector bias

$\gamma = \mathrm{vec}(V, \theta_{bias}) \in \mathbb{R}^{n_\gamma}$, với $n_\gamma = (n_\phi + 1) \cdot n_\theta = 5124$

02

KIẾN TRÚC

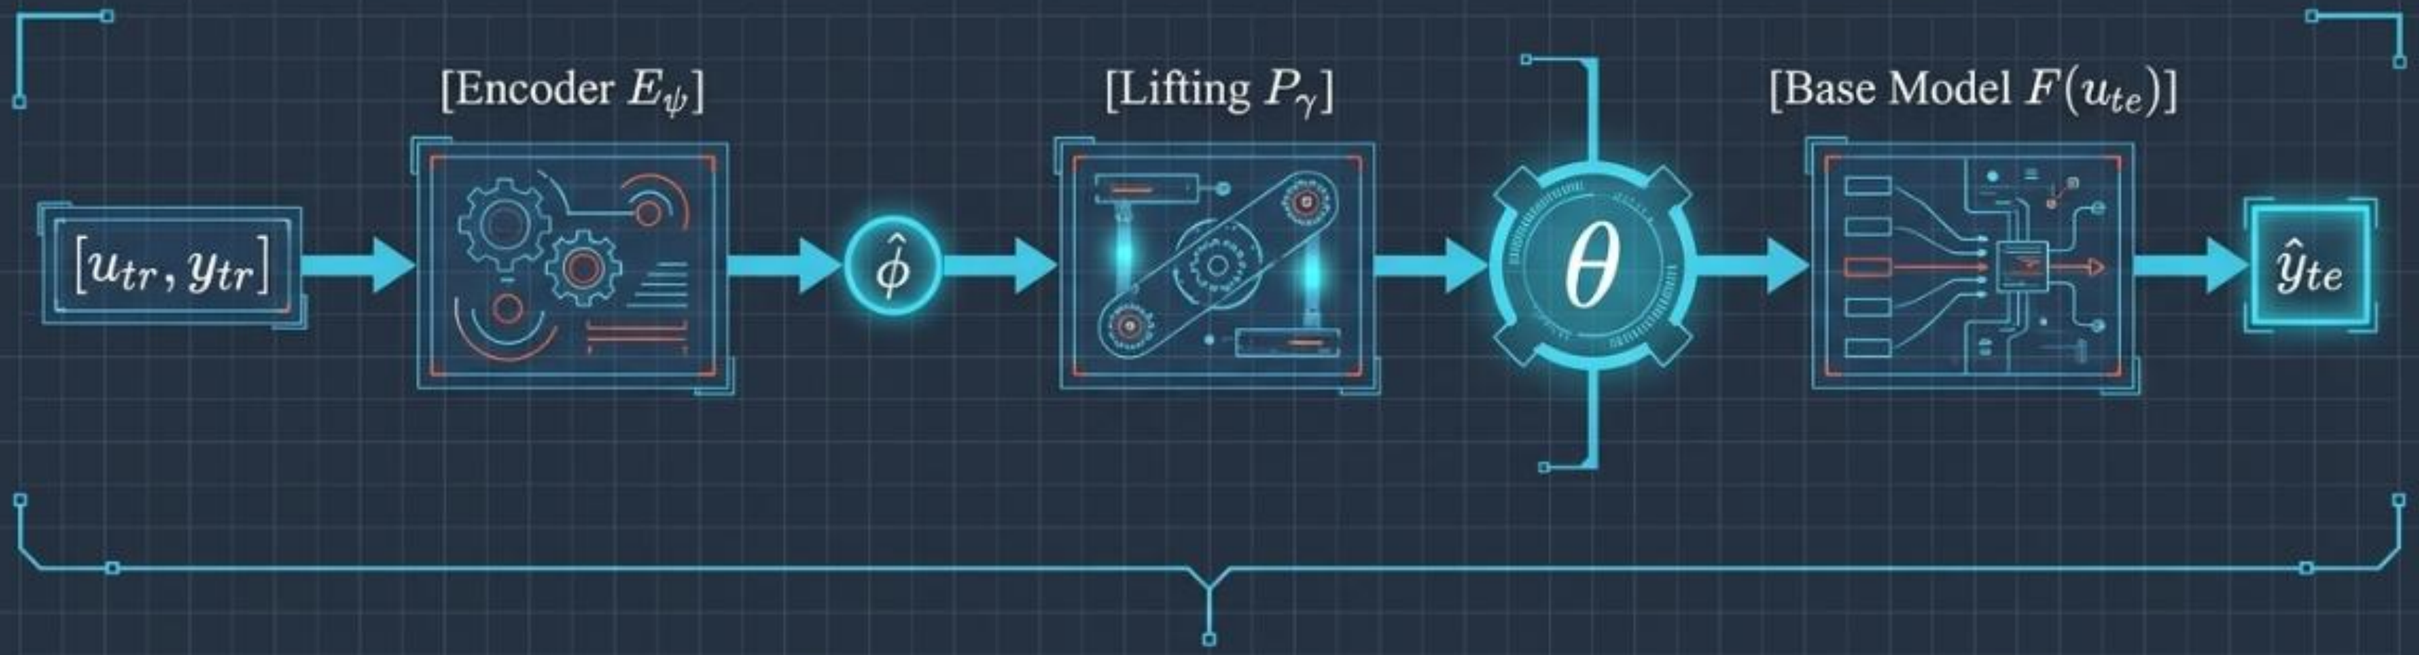

$$\min_{\gamma,\psi} \mathbb{E}_{p(D)} \left[\mathcal{L}\left(y_{te}, F(u_{te}; P_\gamma(E_\psi(u_{tr}, y_{tr})))\right) \right]$$

02

HÀM LOSS & TỐI ƯU

trên tập meta-train

J(γ, ψ)

Meta-training loss

$$J(\gamma, \psi) = \mathbb{E}_{p(\mathcal{D})}\left[\mathcal{L}(y_{te}, \hat{y}_{te})\right]$$

Gradient descent

argmin

γ, ψ

Adam optimizer

batch b = 128

lr $2\times10^{-4} \rightarrow 2\times10^{-5}$

(cosine decay)

meta-test ready

(γ̂, ψ̂)

Tham số

tối ưu

$$(\hat{\gamma}, \hat{\psi}) = \arg\min_{\gamma, \psi} \tilde{J}(\gamma, \psi)$$

cập nhật gradient mỗi batch

$$\mathcal{L}(y, \hat{y}) = \frac{1}{N}\sum_{k=1}^{N} \|y_k - \hat{y}_k\|_2^2$$

03 BÀI TOÁN BOUC-WEN

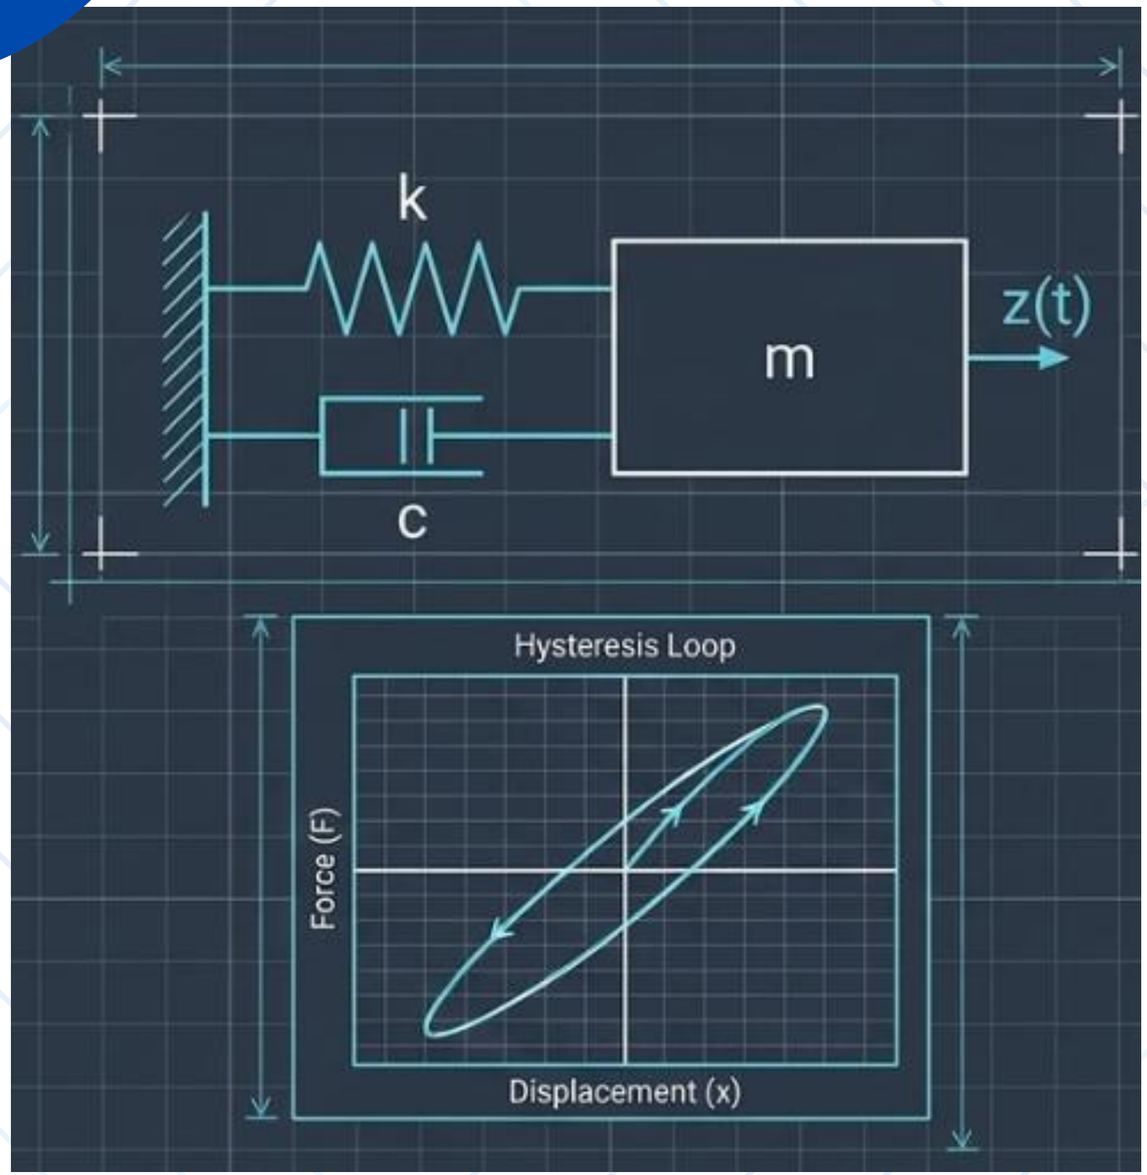

Meta-dataset:

- Hệ cơ học có hiện tượng trễ (hysteretic) phi tuyến cực kỳ khó mô hình hóa.
- Các hệ thống Bouc-Wen có khối lượng m, độ cứng lò xo k, và các hệ số phi tuyến thay đổi ngẫu nhiên.

Chỉ số đánh giá (Metrics):

- FIT (%): Mức độ khớp tín hiệu (Càng cao càng tốt, tương tự R^2).
- RMSE: Căn bậc hai sai số toàn phương trung bình (Càng thấp càng tốt).

03

DỮ LIỆU

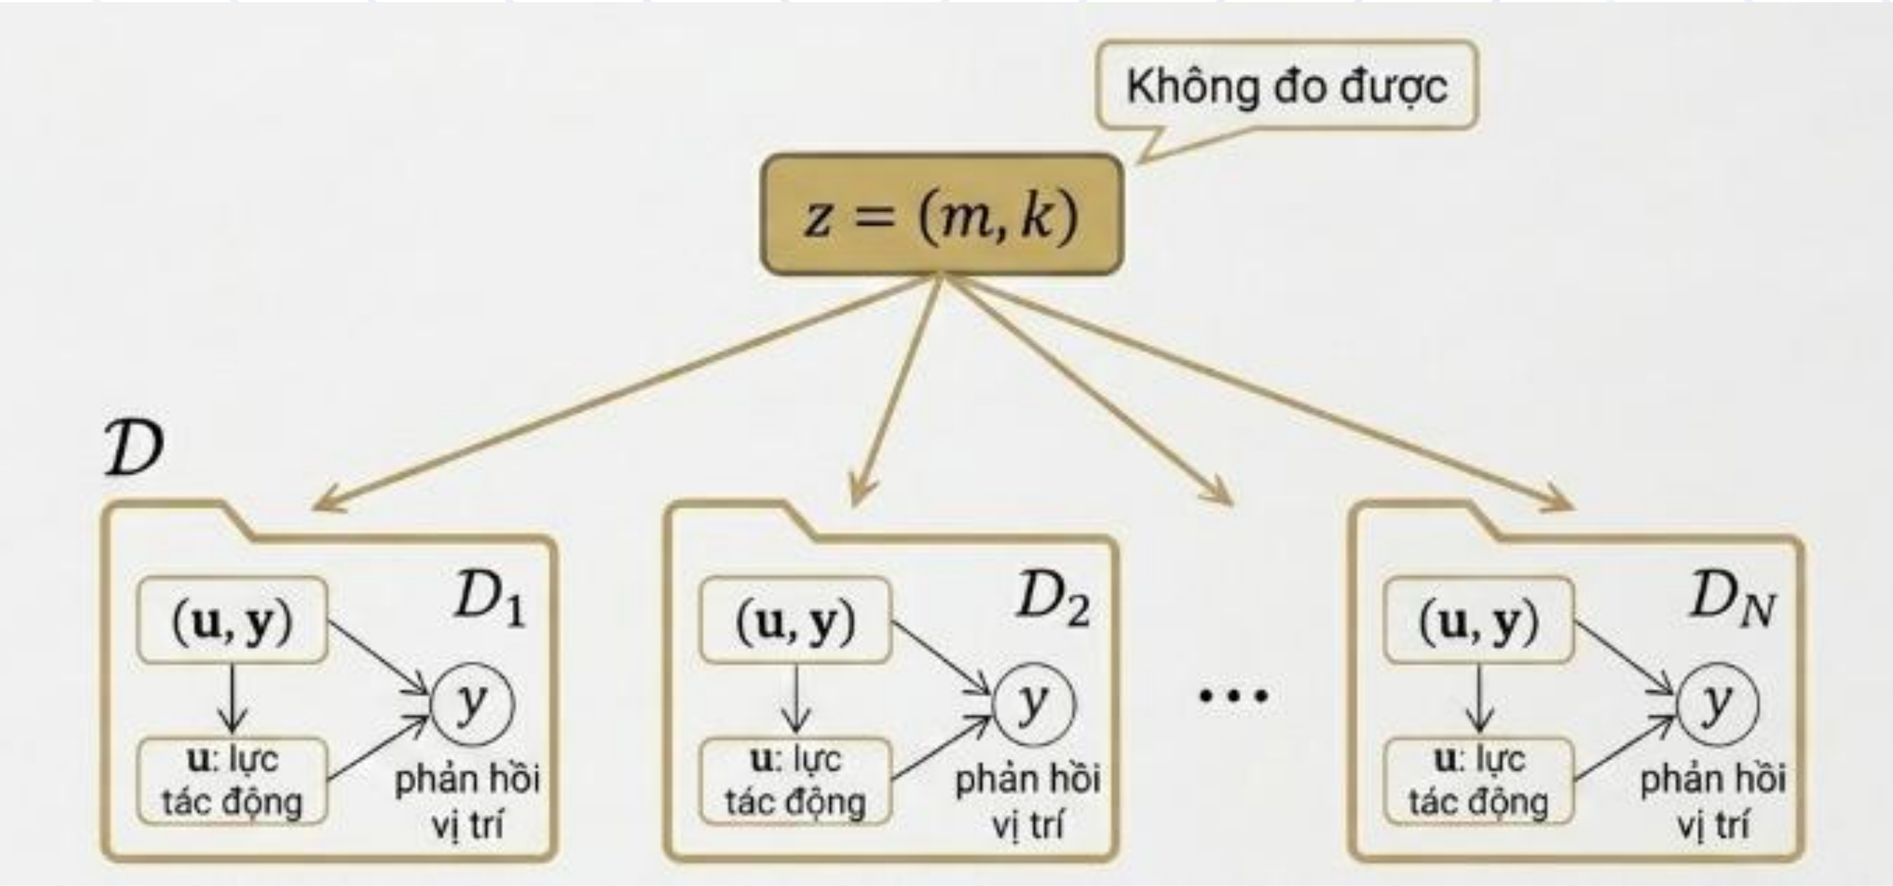

$$p(\mathcal{D}) = p(\mathbf{u}) \cdot \int p(\mathbf{z}) p(\mathbf{y}|\mathbf{u}, \mathbf{z}) dz$$

03

DỮ LIỆU

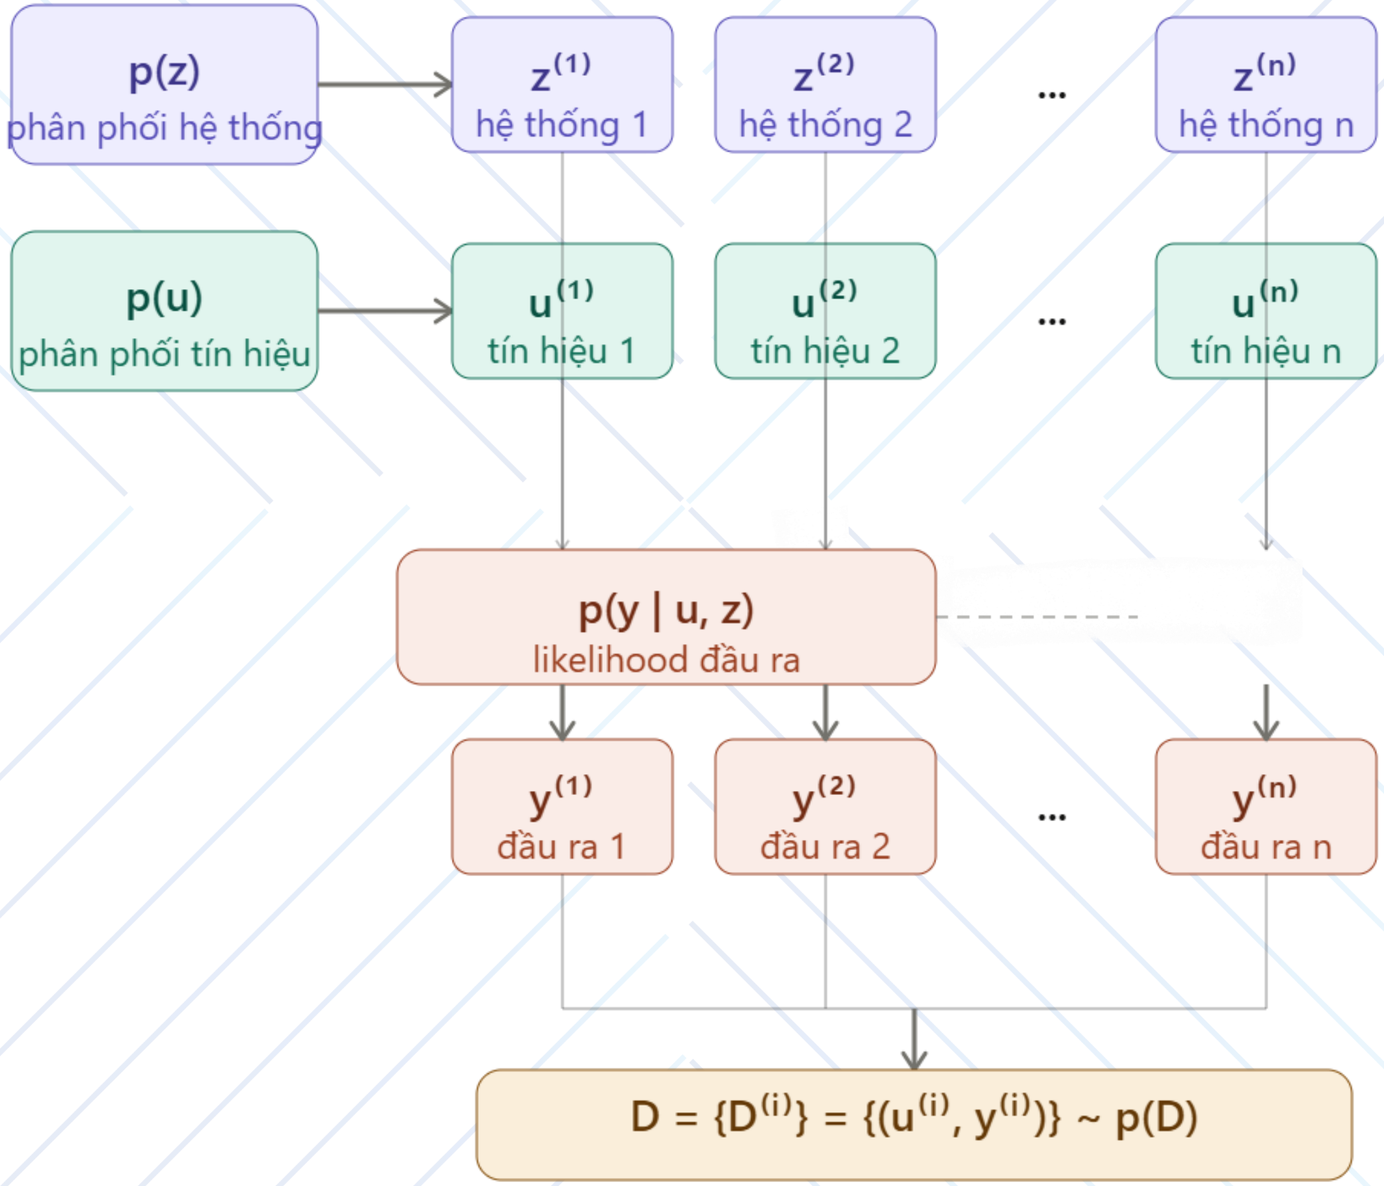
p(z)
phân phối hệ thống
z(1)
hệ thống 1
z(2)
hệ thống 2
...
z(n)
hệ thống n
p(u)
phân phối tín hiệu
u(1)
tín hiệu 1
u(2)
tín hiệu 2
...
u(n)
tín hiệu n
p(y | u, z)
likelihood đầu ra
y(1)
đầu ra 1
y(2)
đầu ra 2
...
y(n)
đầu ra n
D = {D(i)} = {(u(i), y(i))} ~ p(D)

03 F: NEURAL STATE-SPACE

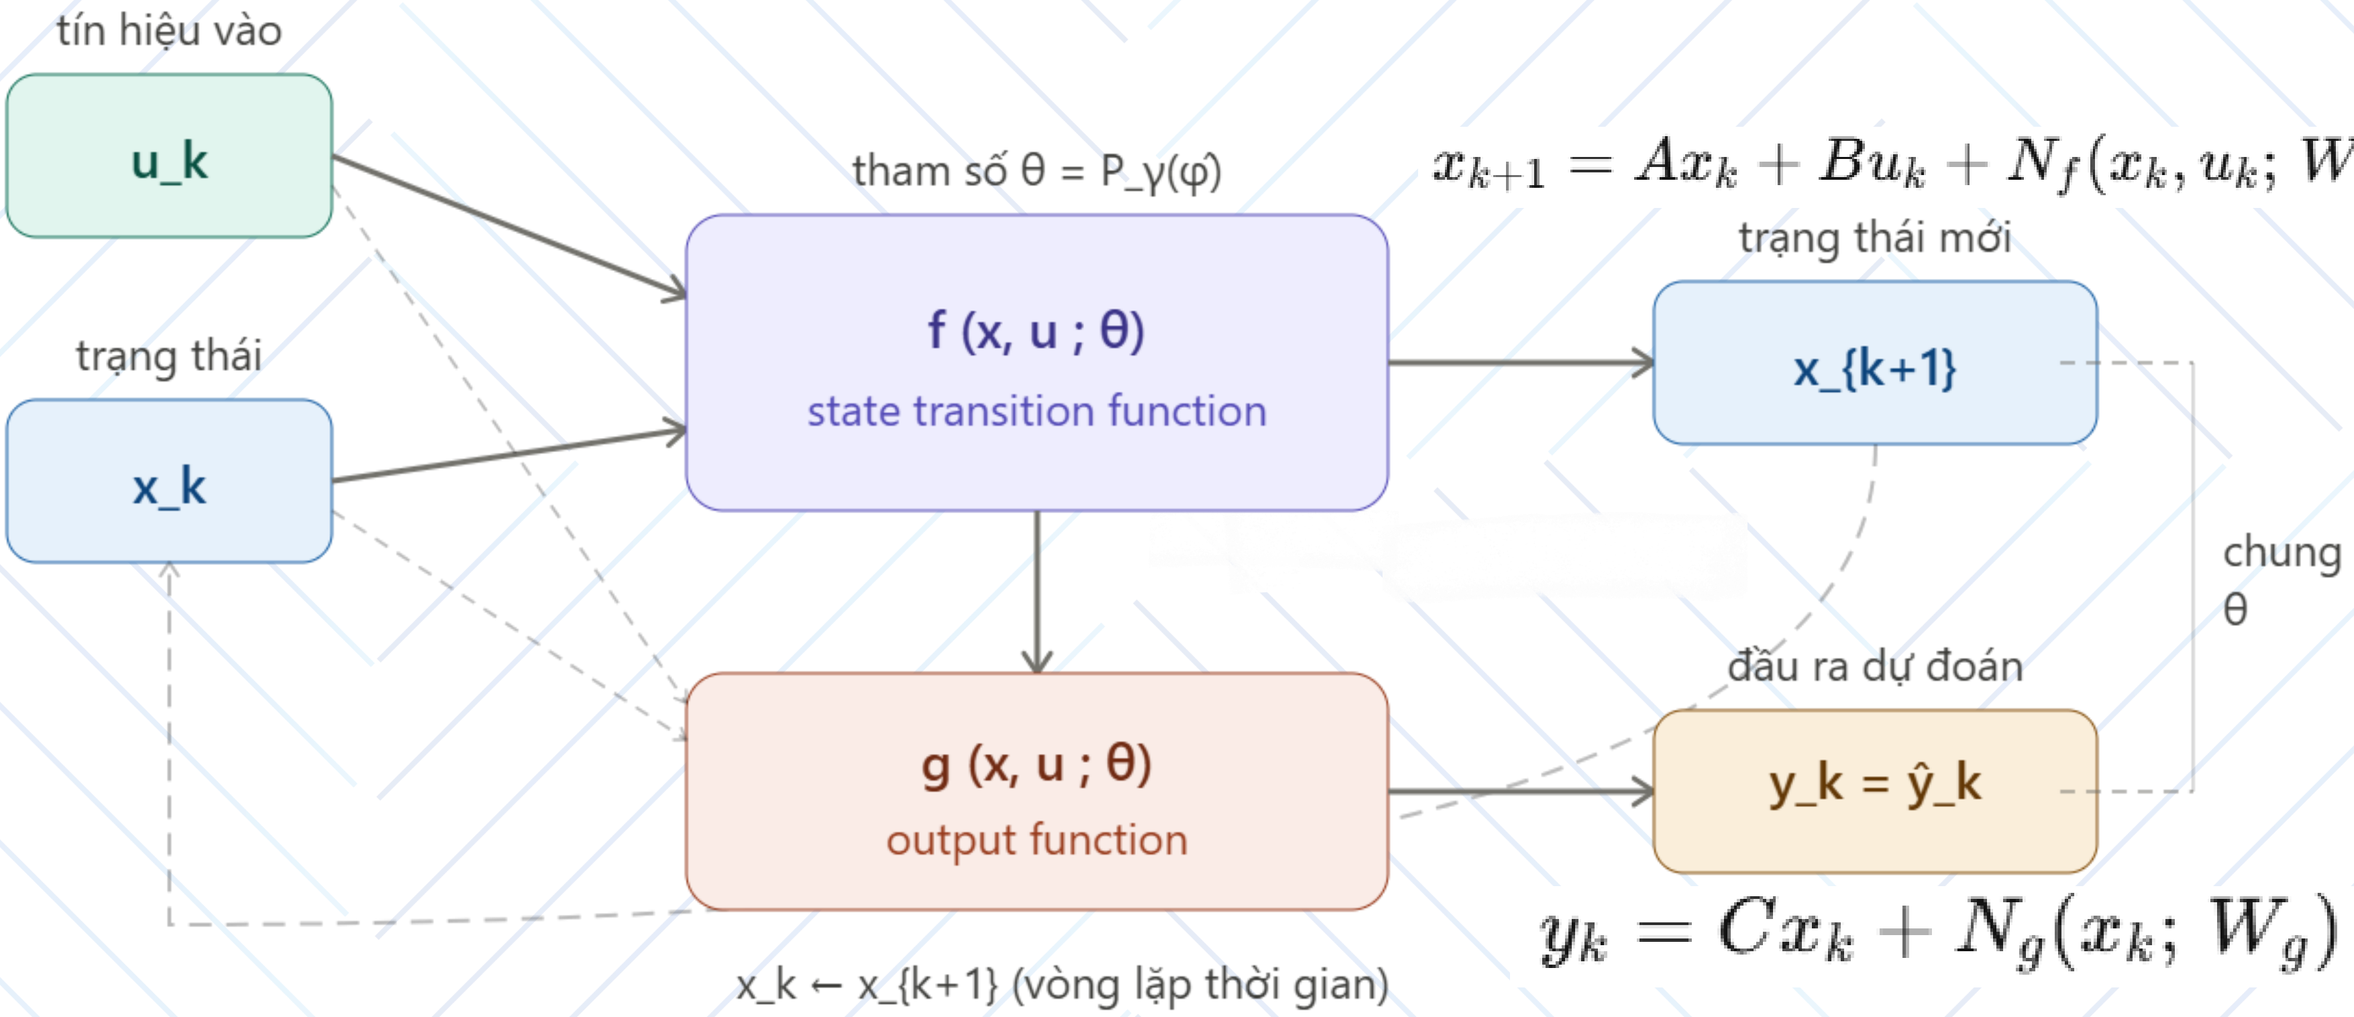

$$x_{k+1} = Ax_k + Bu_k + N_f(x_k, u_k; W_f)$$

$$y_k = Cx_k + N_g(x_k; W_g)$$

04

THỰC NGHIỆM

Dữ liệu lớn

Data lớn
nhiều tác vụ

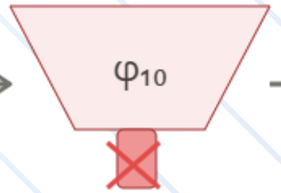

Kém
thông tin bị mất

phễu quá nhỏ
→ tắc nghẽn

Data lớn
nhiều tác vụ

Tốt
học được cấu trúc

phễu vừa đủ
→ luồng thông tin

Dữ liệu rất nhỏ (L = 100)

Data nhỏ
L = 100

y clone
ghi nhớ nguyên vẹn

phễu nhỏ
→ overfit

Data nhỏ
L = 100

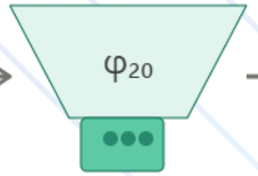

y tổng quát
học được cấu trúc

phễu vừa đủ
→ tổng quát hóa

φ_{10} — phễu nhỏ (bottleneck / overfit)

φ_{20} — phễu vừa (học được cấu trúc)

04

CHIỀU CỦA MANIFOLD

10 CHIỀU

Tốt ở môi trường ít dữ liệu (100 mẫu) nhưng lại kém hơn khi nhiều dữ liệu do không thể biểu diễn hết được.

20 CHIỀU

Đủ tốt để biểu diễn dữ liệu phức tạp, đủ nhỏ để chống hiện tượng overfitting.

Kích thước của không gian đa tạp (manifold) cần tỷ lệ thuận với số lượng biến ẩn (z) chi phối hệ thống vật lý.

05 HẠN CHẾ VÀ GIẢI PHÁP

Dữ liệu mới $D^* = (u^*, y^*)$
tác vụ chưa thấy lúc meta-training

↓

Encoder $E_\psi(u^*, y^*)$
1× forward pass — không gradient

$\varphi_0 \in \mathbb{R}^{20}$
khởi tạo

↓

vòng tinh chỉnh (test-time)

AdamW
~10 000 iterations
tinh chỉnh φ từ φ_0

$\varphi^* = \text{argmin}\ L(y^*, F(u^*; P_\gamma(\varphi)))$

↓

φ^* (tối ưu cho D^*)
tinh chỉnh từ khởi điểm tốt → hội tụ nhanh

$\hat{y}^* = F(u^*; P_\gamma(\varphi^*))$

Encoder only
nhanh nhưng xấp xỉ

AdamW từ random
chính xác nhưng chậm

Encoder + AdamW
nhanh và chính xác

xấp xỉ tốt, chưa tối ưu

chính xác, tốn iteration

nhanh và chính xác

Encoder
đọc toàn bộ D^*
→ ước lượng φ^*
trong 1 forward pass
không tối ưu gradient

AdamW
tối ưu gradient thực
→ tìm chính xác φ^*
từ random: rất nhiều bước
từ φ_0 tốt: ít bước

Hybrid
Encoder → φ_0 gần đúng
AdamW → φ^* chính xác
tốc độ hội tụ cao
chất lượng dự đoán tốt nhất

05

TỔNG KẾT

	MAML	LEO	Manifold
Không gian tối ưu	theta lớn	latent nhỏ	phi nhỏ
Inner loop	có gradient descent	có gradient descent	không có
Chi phí	cao	trung bình	thấp nhất

Nhập Môn Học Máy

GVHD: PGS.TS. Lê Hoàng Thái, ThS. Huỳnh Lâm Hải Đăng

THANK YOU FOR LISTENING

Ninepls

TÀI LIỆU THAM KHẢO

- Rusu, A. A., Rao, D., Sygnowski, J., Vinyals, O., Pascanu, R., Osindero, S., & Hadsell, R. (2019). Meta-learning with latent embedding optimization. International Conference on Learning Representations (ICLR).
- Vuorio, R., Sun, S. H., Hu, H., & Lim, J. J. (2019). Multimodal model-agnostic meta-learning via task-aware modulation. Advances in Neural Information Processing Systems (NeurIPS).
- Sener, O., & Koltun, V. (2020). Learning to guide random search on manifolds. International Conference on Learning Representations (ICLR).

- Finn, C., Abbeel, P., & Levine, S. (2017). Model-agnostic meta-learning for fast adaptation of deep networks. International Conference on Machine Learning (ICML).
- Snell, J., Swersky, K., & Zemel, R. (2017). Prototypical networks for few-shot learning. Advances in Neural Information Processing Systems (NeurIPS).
- Vinyals, O., Blundell, C., Lillicrap, T., & Wierstra, D. (2016). Matching networks for one shot learning. Advances in Neural Informatio Processing Systems (NeurIPS).

- Sanderson, G. (3Blue1Brown). Manim – Mathematical Animation Engine.

PHỤ LỤC

- **Video**: https://www.youtube.com/watch?v=ooIuS76dxA0
- **GitHub**: https://github.com/Thinh59/Manifold-MetaLearning-Manim-Video